



UNIVERSIDADE ESTADUAL DE CAMPINAS  
INSTITUTO DE MATEMÁTICA, ESTATÍSTICA E  
COMPUTAÇÃO CIENTÍFICA

## **Trabalho de Análise Numérica**

Prof. Dr. Maicon Ribeiro Correa

Gabriel Passos	RA:172351
Giovana Marques	RA:197908
João Luiz	RA:199657
Vinícius Martins	RA:206853

19 de Julho de 2019.

## 1 Introdução

Neste trabalho implementamos os algoritmos de Cholesky, Gram-Schmidt e QR por Rotações de Givens, vistos em aula, os quais são utilizados para resolver sistemas lineares através da manipulação de matrizes. Obtemos as inversas das Matrizes de Hilbert de ordens 3, 6 e 13, as quais são dadas pela fórmula:

$$h_{ij} = \frac{1}{i+j-1} \quad (1)$$

Por exemplo:

$$H_3 = \begin{pmatrix} 1 & \frac{1}{2} & \frac{1}{3} \\ \frac{1}{2} & \frac{1}{3} & \frac{1}{4} \\ \frac{1}{3} & \frac{1}{4} & \frac{1}{5} \end{pmatrix}$$

Também calculamos o resíduo gerado na inversão das matrizes pra cada algoritmo e o número de condicionamento de cada matriz, que é uma propriedade que quantifica a sua estabilidade quanto à propagação de erros na resolução de sistemas lineares. Dessa maneira, é esperado que a Matriz de Hilbert torne-se cada vez mais mal condicionada a medida que aumentamos a sua ordem.

O número de condicionamento  $\mathcal{K}$  de uma matriz  $A$  é dado da seguinte maneira

$$\mathcal{K}_m(A) = \|A\|_m \cdot \|A^{-1}\|_m$$

onde  $\|\cdot\|_m$  é a norma matricial desejada

Muitas vezes, o cálculo da inversa de  $A$  pode ser inviável e podemos partir para o cálculo de uma aproximação utilizando um limitante inferior como mostrado abaixo.

$$\mathcal{K}_m(A) \geq \frac{\|a_i\|_m}{\|a_j\|_m} \quad i \neq j$$

onde  $a_k$  é a  $k$ -ésima coluna de  $A$  e  $\|\cdot\|_m$  é a norma- $m$  de vetores dada por

$$\|x\|_m := \left( \sum_{i=1}^n |x_i|^m \right)^{1/m}$$

Um segundo limitante inferior para  $\mathcal{K}_m$  pode ser determinado através de:

$$\mathcal{K}_m(A) \geq \frac{\|A\|_m \|A^{-1}w\|_m}{\|w\|_m}$$

onde, tomando  $w$  suficientemente próximo da direção de magnificação de  $A$ , esse limitante inferior se torna uma excelente estimativa para  $\mathcal{K}_m$

Para cálculo do número de condicionamento foi utilizado a seguinte norma matricial

$$\|A\|_1 := \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$$

Destaca-se que é possível determinar as entradas  $(H_n^{-1})_{ij}$  de  $H_n^{-1}$  em termos dos valores de  $i$  e  $j$ . Essa relação é dada por:

$$(H_n^{-1})_{ij} = (-1)^{i+j} (i+j-1) \binom{n+i-1}{n-j} \binom{n+j-1}{n-i} \binom{i+j-2}{i-1}^2$$

Assim, é possível utilizar essa forma de  $H_n^{-1}$  para realizar comparações com os resultados obtidos pelos métodos.

É importante ressaltar que não estamos interessados na forma da inversa da matriz de Hilbert e sim em suas propriedades. Dessa maneira, ao resolver o sistema  $H_n X = Id$  onde  $X = H_n^{-1}$  e calculamos o resíduo definido por

$$\|H_n \bar{X} - Id\|_2$$

onde  $\bar{X}$  é a solução obtida com os algoritmos descritos posteriormente. Dessa maneira, resíduos pequenos indicam que a solução obtida está próxima da solução teórica, pois nestes algoritmos lidamos com erros de ponto flutuante que se propagam para a solução.

## 2 Algoritmos

### 2.1 Cholesky

A Decomposição de Cholesky decompõe uma matriz positiva-definida em uma matriz triangular inferior e uma triangular superior da forma  $A = R^T R$ , onde  $R$  possui elementos na diagonal todos positivos, o que torna a decomposição única. Assim podemos resolver um sistema  $Ax = b$  da forma

$$Q^T y = b \quad (2)$$

$$Rx = y \quad (3)$$

### 2.2 QR por Gram-Schmidt

O algoritmo de Gram-Schmidt Clássico realiza a decomposição  $A = QR$ , em que  $A \in \mathbb{R}^{m \times n}$ ,  $Q \in \mathbb{R}^{m \times n}$  e  $R \in \mathbb{R}^{n \times n}$  triangular superior. Ele consiste em ortonormalizar o conjunto de vetores  $\mathbf{v} = \mathbf{v}_1, \dots, \mathbf{v}_k$  que forma a matriz  $A$  através do seguinte processo:

$$\mathbf{u}_k = \mathbf{v}_k - \sum_{j=1}^{k-1} \frac{\langle \mathbf{v}_k, \mathbf{u}_j \rangle}{\langle \mathbf{u}_j, \mathbf{u}_j \rangle} \mathbf{u}_j$$

$$\mathbf{q}_k = \frac{\mathbf{u}_k}{\|\mathbf{u}_k\|}$$

### 2.3 QR por Rotação de Givens

A Rotação de Givens decompõe  $A = QR$  zerando um elemento a cada rotação de forma a obter  $Q \in \mathbb{R}^{m \times m}$  ortogonal e  $R \in \mathbb{R}^{m \times n}$  triangular superior. Para zerar o elemento  $A_{ij}$  basta fazer  $GA$  em que os elementos não nulos de  $G$  são dados por:

$$g_{kk} = 1 \quad \text{para } k \neq i, j$$

$$g_{ii} = g_{jj} = \cos \theta$$

$$g_{ij} = -\sin \theta$$

$$g_{ji} = \sin \theta$$

em que

$$\sin \theta = \frac{a_{ij}}{\sqrt{a_{ij}^2 + a_{ii}^2}}$$

$$\cos \theta = \frac{a_{ii}}{\sqrt{a_{ij}^2 + a_{ii}^2}}$$

As matrizes  $R$  e  $Q$  serão dadas por:

$$G_n^T G_{n-1}^T \dots G_1^T A = R$$

$$G_1 G_2 \dots G_n = Q$$

## 3 Resultados

Os testes computacionais foram executados para matrizes de ordem 3, 6, 13 e 200. Nenhum algoritmo apresentou erro para as dimensões 3, 6, 13. Entretanto, o algoritmo da fatoração de Cholesky, capaz de verificar se uma matriz é positiva-definida, conclui que  $H_n$  não é positiva-definida para  $n \geq 14$ , assim,  $H_n$  não possui fator de Cholesky para  $n \geq 14$ . Ressalta-se o fato de que  $H_n$  é positiva definida para qualquer  $n$ , logo, devido a erros numéricos, a conclusão do algoritmo é falha. Para avaliar o comportamento dos demais algoritmos em dimensões maiores  $H_n$ , optou-se por testar o caso  $n = 200$ . Serão apresentadas fatorações obtidas por cada algoritmo para o caso  $n = 3$ . Os resultados são apresentados nas Tabelas 1, 2 e 3.

### 3.1 Resultados para $n = 3$

Para  $H_3$ , como esperado, a inversa obtida pelos três algoritmos foi idêntica, dada por:

$$H_3^{-1} = \begin{pmatrix} 9 & -36 & 30 \\ -36 & 192 & -180 \\ 30 & -180 & 180 \end{pmatrix}$$

As fatorações obtidas pelos algoritmos foram:

- **Cholesky**

$$R = \begin{pmatrix} 1 & 0.5 & 0.333 \\ 0 & 0.288 & 0.288 \\ 0 & 0 & 0.074 \end{pmatrix}$$

- **QR por Gram-Schmidt**

$$Q = \begin{pmatrix} 0.857 & -0.501 & 0.117 \\ 0.428 & 0.568 & -0.702 \\ 0.285 & 0.652 & 0.702 \end{pmatrix}$$

$$R = \begin{pmatrix} 1.166 & 0.642 & 0.45 \\ 0 & 0.101 & 0.105 \\ 0 & 0 & 0.003 \end{pmatrix}$$

- **QR por Rotação de Givens**

$$Q = \begin{pmatrix} 0.857 & -0.501 & 0.117 \\ 0.428 & 0.568 & -0.702 \\ 0.285 & 0.652 & -0.702 \end{pmatrix}$$

$$R = \begin{pmatrix} 1.166 & 0.642 & 0.45 \\ 0 & 0.101 & 0.105 \\ 0 & 0 & 0.003 \end{pmatrix}$$

Cholesky						
n	$\ \tilde{H}^{-1} - H^{-1}\ _1$	$\ H\tilde{H}^{-1} - I\ _1$	$k_1$	$\tilde{k}_1^1$	$\tilde{k}_1^2$	$\tilde{k}_1^3$
3	1,528E-12	2,050E-14	7,480E+02	7,480E+02	2,340	7,480E+02
6	1,000E-04	2,285E-09	2,907E+07	2,907E+07	3,326	1,312E+07
13	4,889E+17	6,473E+03	1,324E+18	2,879E+18	4,462	9,343E+17
200	—	—	—	—	—	—

Table 1: Resultados para fatoração de Cholesky

QR por Gram-Schmidt						
n	$\ \tilde{H}^{-1} - H^{-1}\ _1$	$\ H\tilde{H}^{-1} - I\ _1$	$k_1$	$\tilde{k}_1^1$	$\tilde{k}_1^2$	$\tilde{k}_1^3$
3	3,143E-11	5,002E-12	7,480E+02	7,480E+02	2,340	7,480E+02
6	6,351E+02	3,470E-02	2,907E+07	2,907E+07	3,326	1,312E+07
13	4,165E+17	8,262E+03	1,324E+18	1,720E+09	4,462	4,563E+08
200	2,221E+303	2,370E+08	1,306E+304	1,302E+11	8,465	2,039E+09

Table 2: Resultados para fatoração QR por Gram-Schmidt

QR por Rotação						
n	$\ \tilde{H}^{-1} - H^{-1}\ _1$	$\ H\tilde{H}^{-1} - I\ _1$	$k_1$	$\tilde{k}_1^1$	$\tilde{k}_1^2$	$\tilde{k}_1^3$
3	6,565E-12	2,409E-14	7,480E+02	7,480E+02	2,340	7,480E+02
6	4,000E-04	1,504E-09	2,907E+07	2,907E+07	3,326	1,312E+07
13	4,099E+16	1,591E+03	1,324E+18	1,194E+18	4,462	3,892E+17
200	1,740E+15	2,221E+303	1,306E+304	2,640E+21	8,465	1,012E+20

Table 3: Resultados para fatoração QR por Rotações de Givens